

Пермский филиал федерального государственного автономного
образовательного учреждения высшего образования
«Национальный исследовательский университет
«Высшая школа экономики»

Факультет социально-экономических и компьютерных наук

Билык Екатерина

Лучков Павел

Триллер Анна

**ОЦЕНКА ВЕРОЯТНОСТИ ДЕФОЛТА (PD) ДЛЯ МАЛЫХ И СРЕДНИХ
ЗАЕМЩИКОВ С ИСПОЛЬЗОВАНИЕМ МЕТОДОВ МАШИННОГО
ОБУЧЕНИЯ**

Итоговый проект по дисциплине «Риск-менеджмент» студентов
образовательной программы «Международный бакалавриат по бизнесу и
экономике»

Руководитель:

Преподаватель факультета финансовых наук

Егоров Андрей Юрьевич

Пермь, 2025

Содержание

Введение.....	3
Теоретические основы оценки кредитных рисков в сегменте малого и среднего предпринимательства.....	6
Введение в ключевые понятия и контекст	6
Факторы прогнозирования банкротства: специфика МСП	8
Практическая значимость	11
Гипотезы исследования.....	13
Методология исследования и сбор исходных данных для анализа рисков.....	15
Формирование выборки и источники данных	15
Выбор и обоснование переменных	16
Описание переменных.....	23
Предобработка данных.....	24
Методы моделирования и валидации	25
Первичный анализ данных	27
Построение, валидация и сравнение альтернативных моделей оценки риска	34
Логистическая регрессия (Logistic Regression).....	34
Градиентный бустинг (CatBoost).....	41
Сравнительный анализ качества построенных моделей оценки кредитных рисков	46
Ограничения моделей.....	48
Рекомендации.....	50
Рекомендации для кредитных организаций	50
Рекомендации для регуляторов финансового рынка	52
Рекомендации для субъектов малого и среднего предпринимательства	53
Заключение.....	54
Список источников.....	58

Введение

В современных экономических условиях малые и средние предприятия (МСП) составляют значительную часть экономики и одновременно характеризуются повышенным кредитным риском. Эффективная оценка вероятности дефолта (PD) МСП имеет критическое значение для банков и регуляторов при принятии решений о кредитовании и формировании резервов. Настоящая работа направлена на разработку и валидацию модели прогнозирования PD для отечественных МСП с использованием реальных данных из базы СПАРК. В модели используются как классические финансовые показатели компаний (ликвидность, рентабельность, доля собственного капитала и т.д.), так и макроэкономические переменные (ВРП на душу, курс USD/RUB, индекс предпринимательской уверенности, ключевая ставка). В качестве алгоритмов прогнозирования применяются логистическая регрессия и современные методы машинного обучения (градиентный бустинг CatBoost). Это позволит глубоко проанализировать влияние внутренних и внешних факторов на кредитный риск МСП и оценить преимущества ML-подходов.

Цель исследования: Разработка и практическая оценка модели прогнозирования вероятности дефолта российских МСП на основе методов статистического анализа и машинного обучения.

Задачи исследования:

1. Провести анализ специфики кредитного риска в сегменте МСП и существующих подходов к его оценке.
2. Сформировать и подготовить репрезентативную выборку данных по МСП из СПАРК (финансовые показатели, признаки деятельности, макроэкономика).
3. Построить базовую логистическую модель вероятности дефолта и оценить её качество (AUC-ROC, Gini, KS).

4. Разработать модель градиентного бустинга (CatBoost) для прогнозирования PD с подбором оптимальных признаков и гиперпараметров.
5. Провести сравнение и валидацию моделей по стандартным метрикам, включающую анализ устойчивости (кросс-валидация, тест на стабильность) и стресс-тестирование.
6. Обеспечить соответствие модели нормативным требованиям (IFRS9, Basel/BN RF) через объяснимость (SHAP/LIME) и формирование отчетной документации.

Объект исследования: Кредитные риски, связанные с кредитованием субъектов малого и среднего предпринимательства (МСП).

Предмет исследования: Процедуры и инструменты оценки вероятности дефолта (PD) МСП, основанные на финансовых данных и применении методов машинного обучения.

Ключевыми стейкхолдерами проекта являются:

- Кредитные организации и банки, кредитующие МСП и нуждающиеся в точной оценке их кредитного качества;
- Государственные органы поддержки МСП и регуляторы (Центробанк РФ, Министерство экономического развития, Корпорация «МСП»), курирующие финансовые программы и требующие прозрачных методик оценки рисков;
- МСП и их собственники, заинтересованные в справедливом доступе к кредитным ресурсам при объективной оценке рисков;
- Инвестиционные и аналитические агентства, оценивающие кредитоспособность МСП-секторов и влияющие на принятие решений инвесторами.

Кредитование МСП является приоритетным направлением государственной политики: этот сектор способствует диверсификации экономики и созданию рабочих мест. Одновременно МСП традиционно

испытывают трудности с доступом к финансированию из-за нестабильности денежного потока и ограниченной отчётности. **Актуальность** разработки надежной модели PD для МСП обусловлена ростом неопределенности в экономике и необходимостью банков более точно оценивать риск портфелей МСП. В то же время банковские регуляторы (IFRS 9, Базельский комитет) требуют включения в модели прогнозов макроэкономических сценариев и адекватной валидации. Применение методов машинного обучения позволяет повысить точность прогнозов и учесть нелинейные зависимости при больших объемах данных.

В российском контексте, на фоне цифровизации и доступности данных (СПАРК), возникает возможность разработки специализированной PD-модели МСП, адаптированной под локальные экономические условия.

Новизна работы заключается в интеграции классических и ML-подходов для анализа дефолтности МСП в России. Во-первых, впервые создаётся комплексная модель оценки PD для МСП на основе реальных данных СПАРК, объединяющая фирменные финансовые коэффициенты и макроэкономические индикаторы. Во-вторых, в ней сочетается статистическая логистическая модель с современным алгоритмом CatBoost, что позволяет захватить сложные нелинейные эффекты. В-третьих, разработан подход объяснения модели с помощью методик интерпретируемости (например, SHAP), обеспечивающий прозрачность для бизнеса и регуляторов. Таким образом, научная новизна работы заключается в адаптации методов ML и сценарного анализа к спецификам МСП-сегмента в России.

Теоретические основы оценки кредитных рисков в сегменте малого и среднего предпринимательства

Введение в ключевые понятия и контекст

Малые и средние предприятия (МСП) — предприятия, составляющие пятую часть всего внутреннего валового продукта России за 2024 год [1] и классифицируются по трем критериям [2]:

- среднесписочную численность работников;
- годовой доход;
- состав уставного (складочного) капитала.

МСП играют ключевую роль в экономике, выступая драйвером рыночной экономики в большинстве развитых стран мира. Так, например, в странах Организации экономического сотрудничества и развития МСП представляет собой 99% всего бизнеса и обеспечивает от 50% до 60% добавленной стоимости, процветая на нишевых и местных рынках, а также конкурируя в глобальных цепочках экономики. [3]. Малый и средний бизнес характеризуется большим оказываемым на него рыночным давлением: МСП сталкиваются с ограниченным доступом к кредитным ресурсам, высокой конкуренцией со стороны крупного бизнеса и бюрократическими барьерами [3] и полагаются, в большинстве, на собственный капитал [4].

Малые и средние предприятия (МСП) исторически играют ключевую роль в экономике, однако их финансовая устойчивость значительно ниже по сравнению с крупным бизнесом. Как отмечают исследователи, эффективное прогнозирование дефолтов МСП привлекает внимание академического сообщества и банковского сектора еще с 1970-х годов, но особую актуальность эта тема приобрела после внедрения Базельских соглашений (Basel II) в 2004 году. Эти регуляторные требования обязали банки рассчитывать достаточность капитала на основе внутренних рейтинговых систем (IRB), что потребовало создания точных моделей оценки риска именно для сегмента МСП (*Ciampi, 2015; Altman & Sabato, 2007*).

Необходимость совершенствования моделей прогнозирования дефолтов (Probability of Default, PD) обостряется в периоды экономических потрясений. Глобальный финансовый кризис 2007–2009 годов и пандемия COVID-19 продемонстрировали, что МСП подвержены «физиологической финансовой слабости» в большей степени, чем крупные корпорации (*Adian et al., 2020*). Исследования показывают, что в кризисные периоды традиционные модели, построенные на исторических данных, теряют свою предсказательную силу, так как компании могут прибегать к «неортодоксальным» методам бухгалтерского учета, чтобы отсрочить выявление проблем (*Ciampi, 2018*).

Ключевым вызовом при оценке вероятности дефолта МСП является высокая информационная асимметрия (information opacity). В отличие от крупных публичных компаний, МСП предоставляют значительно меньше открытой информации, а их финансовая отчетность часто бывает непрозрачной или запаздывающей (*Berger et al., 2005; Frame & Woosley, 2004*).

В систематическом обзоре литературы *Ciampi et al. (2021)* выделяют, что традиционные подходы, опирающиеся исключительно на финансовые коэффициенты (ликвидность, леверидж, рентабельность), демонстрируют низкую точность для малых фирм (*Altman et al., 2010*). Это связано с тем, что финансовые данные МСП часто не отражают реального положения дел в режиме реального времени. В ответ на это возникла необходимость интеграции «жесткой» финансовой информации с «мягкой» (soft information) — данными о взаимоотношениях с банком, качественными характеристиками менеджмента и, в последнее время, альтернативными данными (Big Data), обработка которых требует применения современных методов машинного обучения (*Alaka et al., 2018; Fosso Wamba et al., 2015*).

Таким образом, переход от классических эконометрических моделей к методам искусственного интеллекта и машинного обучения (ML) обусловлен не только технологическим прогрессом, но и фундаментальной потребностью преодолеть информационный дефицит, характерный для сектора МСП.

Однако информационная непрозрачность — не единственная проблема. Исследования показывают, что модели, основанные исключительно на финансовых коэффициентах, часто игнорируют качественные характеристики управления, которые критичны для малых фирм. В отличие от крупных корпораций, где управление отделено от владения, в МСБ эти функции часто совмещены. *Ciampi (2015)* в своем исследовании итальянских фирм доказал, что включение переменных корпоративного управления (corporate governance variables) значительно повышает точность прогнозирования дефолта. В частности, для малых предприятий характерна иная логика лидерства: если для крупных компаний концентрация власти у CEO считается риском (agency theory), то для МСП «двойственность CEO» (когда гендиректор и председатель совета директоров — одно лицо) положительно влияет на выживаемость, обеспечивая быстроту принятия решений в кризис (*Ciampi, 2015*).

Факторы прогнозирования банкротства: специфика МСП

Выбор предикторов является критическим этапом в построении моделей оценки кредитного риска. Эмпирические данные свидетельствуют о том, что для МСБ, в отличие от крупных корпораций, набор значимых факторов смещается от показателей долгосрочной устойчивости к метрикам операционной эффективности и чувствительности к внешней экономической среде.

1. Операционная эффективность и управление оборотным капиталом

Традиционные модели (Z-Score) часто фокусируются на рентабельности и леверидже. Однако для малых предприятий, работающих в условиях дефицита ликвидности, критически важной становится способность управлять денежными потоками в моменте. Исследования (например, *Ciampi et al., 2021*) подтверждают, что показатели деловой активности (Activity Ratios) служат ранними индикаторами проблем.

Особую роль играет оборачиваемость кредиторской задолженности (Accounts Payable Turnover). Замедление этого показателя

часто является первым сигналом скрытого дефолта: прежде чем компания покажет убыток в отчете о прибылях и убытках, она начинает задерживать платежи поставщикам, чтобы закрыть кассовые разрывы. Также высока значимость коэффициента быстрой ликвидности (Quick Ratio) и оборачиваемости активов, так как они отражают способность менеджмента генерировать выручку на вложенный капитал и покрывать обязательства без распродажи запасов.

2. Макроэкономические детерминанты: уязвимость МСБ

Существенным пробелом ранних моделей (Altman, 1968) было игнорирование внешней среды. Однако современные исследования (Filipe et al., 2016; Ciampi, 2015) доказывают, что МСБ обладают значительно большей чувствительностью к макрошокам, чем крупный бизнес, из-за отсутствия инструментов хеджирования и ограниченного доступа к рынкам капитала.

В контексте развивающихся рынков (включая Россию) ключевыми факторами риска становятся:

- Стоимость фондирования (Ключевая ставка), так как МСП сильно зависят от банковского кредитования с плавающими ставками. Рост ключевой ставки мгновенно увеличивает долговую нагрузку, снижая коэффициент покрытия процентов;
- Поскольку малый бизнес часто локализован, его выживаемость напрямую коррелирует с покупательной способностью в конкретном регионе (Gabbianelli, 2018);
- Даже если компания не ведет ВЭД напрямую, волатильность курса влияет на стоимость закупок и инфляционные ожидания, сжимая маржинальность бизнеса.

3. Классические показатели рентабельности

Несмотря на важность специфических факторов, показатели ROA (Рентабельность активов) и ROE (Рентабельность капитала) остаются фундаментом оценки. Они демонстрируют конечную эффективность бизнес-модели. Однако, как отмечают Altman и Sabato (2007), для МСП эти

показатели стоит рассматривать в динамике и в связке с показателями оборачиваемости, чтобы исключить влияние разовых бухгалтерских операций.

4. Влияние стейкхолдеров и временная динамика дефолта

Важно понимать, что банкротство МСП — это не одномоментное событие, а процесс. *Manzaneque-Lizano et al. (2019)* предлагают рассматривать устойчивость компании через призму теории заинтересованных сторон (Stakeholder Theory). Их исследование на выборке испанских МСП показало, что значимость различных стейкхолдеров меняется по мере приближения к дефолту.

На ранних этапах кризиса (за 3-4 года) ключевую роль играют операционные стейкхолдеры: клиенты (своевременность оплат) и поставщики (готовность предоставлять торговый кредит). На поздних этапах (за 1-2 года) критической становится зависимость от финансовых институтов (кредиторов). Таким образом, модель прогнозирования должна учитывать способность фирмы управлять отношениями с контрагентами, так как поддержка со стороны клиентов и сотрудников (через гибкость зарплат) является буфером против банкротства (*Manzaneque-Lizano et al., 2019*).

2.5. Метрики оценки качества и проблема модельного риска

При переходе к методам машинного обучения (ML) критически важным становится выбор метрик оценки эффективности моделей. В академической литературе «золотым стандартом» для задач кредитного скоринга является **AUC-ROC** (Area Under the Receiver Operating Characteristic Curve), оценивающая способность модели ранжировать заемщиков по вероятности дефолта. *Robisco и Martínez (2022)* в сравнительном анализе алгоритмов на данных о кредитовании отмечают, что ML-модели (в частности, XGBoost и Random Forest) демонстрируют прирост показателя AUC-ROC до 5 процентных пунктов по сравнению с традиционной логистической регрессией.

Однако исключительная фокусировка на точности прогноза (predictive performance) несет в себе скрытые угрозы, известные как «модельный риск» (model risk). Регуляторные требования (Basel II/III) обязывают банки объяснять принятые решения. Сложные модели (например, нейронные сети) часто являются «черными ящиками». *Robisco и Martínez (2022)* предлагают использовать **«риск-взвешенную производительность» (risk-adjusted performance)**, которая учитывает не только точность (AUC-ROC), но и:

- Стабильность (Stability): отсутствие дрейфа предсказаний при изменении выборки;
- Интерпретируемость (Interpretability): возможность объяснить вклад каждого фактора в решение (например, с помощью SHAP-значений);
- Вычислительную эффективность: время обучения и задержка (latency) при получении результата.

Их эмпирические результаты показывают, что алгоритмы градиентного бустинга (XGBoost) являются наиболее эффективными с точки зрения баланса между точностью прогнозирования и модельным риском, превосходя как традиционные методы, так и более сложные глубокие нейронные сети (Deep Learning), интерпретация которых затруднена.

Практическая значимость

Разработка усовершенствованной модели прогнозирования банкротства (PD) несет ценность для широкого круга экономических агентов. Согласно мульти-стейкхолдерному подходу (*Thomas, 2023; Manzanque-Lizano et al., 2019*), можно выделить следующие группы выгодоприобретателей:

1. Финансовые институты (Банки и FinTech-кредиторы) — Основные пользователи.

Выгода: Снижение доли неработающих кредитов (NPL) и соблюдение регуляторных требований (Basel II/III), требующих точной оценки рисков (*Ciampi, 2015*).

Теоретический аспект: Модель снижает информационную асимметрию, позволяя кредитовать качественных заемщиков, которых "отсеивают" старые консервативные скоринги. Для FinTech-компаний это способ масштабирования бизнеса и автоматизации решений (Thomas, 2023).

2. Собственники и менеджмент МСП.

Выгода: Раннее предупреждение (Early Warning System).

Теоретический аспект: Manzanegue-Lizano et al. (2019) подчеркивают, что кризис — это процесс. Модель позволяет собственникам увидеть ухудшение "здоровья" бизнеса на ранней стадии (например, через метрики оборачиваемости долга клиентов), когда еще можно договориться с поставщиками или оптимизировать расходы на персонал, не доводя дело до суда.

3. Контрагенты (Поставщики и Клиенты).

Выгода: Управление цепочками поставок.

Теоретический аспект: Крупные поставщики используют подобные модели для установления лимитов торгового кредитования (отсрочки платежа). Понимание риска контрагента обеспечивает устойчивость всей цепочки создания стоимости.

4. Государство и регуляторы (Центральный банк).

Выгода: Финансовая стабильность и экономический рост.

Теоретический аспект: МСБ — драйвер ВВП. Точные модели позволяют не "перекрывать кислород" бизнесу в кризис (как это было в COVID-19), а оказывать точечную поддержку жизнеспособным компаниям, сохраняя рабочие места (Thomas, 2023).

5. Инвесторы (Venture Capital, Private Equity).

Выгода: Оценка стартапов и зрелых МСБ.

Теоретический аспект: Инвесторы заинтересованы в моделях, которые учитывают не только прошлое (бухгалтерия), но и потенциал роста и качество управления (Ciampi, 2015), чтобы минимизировать риск потери капитала.

Гипотезы исследования

На основе проведенного анализа литературы и выявленных пробелов в существующих подходах к оценке кредитного риска МСБ, в данном исследовании выдвигаются следующие гипотезы:

Гипотеза 1 (H1): Показатели способности к самофинансированию и левериджа являются наиболее значимыми финансовыми предикторами дефолта МСБ.

Обоснование: согласно Altman и Sabato (2007), классические показатели ликвидности (например, Current Ratio), эффективные для крупных корпораций, теряют свою значимость для малых фирм. Вместо этого критическую роль играет отношение нераспределенной прибыли к активам (Retained Earnings / Total Assets). Мы предполагаем, что для МСБ этот показатель служит прокси-метрикой возраста и устойчивости бизнеса, а высокий уровень краткосрочного долга (Short-term Debt) является главным маркером финансовой неустойчивости.

Гипотеза 2 (H2): Макроэкономические факторы (ключевая ставка, динамика ВВП, валютный курс) являются значимыми предикторами дефолта МСБ, сопоставимыми по силе влияния с финансовыми коэффициентами.

Обоснование: Опираясь на выводы *Filipe et al. (2016)*, мы предполагаем, что вероятность дефолта малых предприятий не является идиосинкразической (зависящей только от самой фирмы), а имеет сильную системную компоненту. В периоды макроэкономической нестабильности (рост ставок, девальвация) качество портфеля МСБ ухудшается синхронно, что должно отражаться в высоких значениях feature importance для макропеременных.

Гипотеза 3 (H3): Алгоритмы градиентного бустинга (XGBoost, CatBoost) демонстрируют наилучшую риск-взвешенную производительность (Risk-Adjusted Performance) по сравнению с логистической регрессией и, как следует из литературы, с нейронными сетями при оценке МСП.

Обоснование: Традиционные эконометрические модели (Logit), хотя и обладают высокой интерпретируемостью, уступают в точности современным

методам на 4-5% по метрике AUC-ROC (*Robisco & Martínez, 2022*). С другой стороны, нейронные сети (Deep Learning), показывая высокую точность, несут чрезмерный «модельный риск» из-за сложности интерпретации и настройки гиперпараметров («проблема черного ящика»). Мы предполагаем, что ансамблевые методы на основе деревьев решений (Tree-based ensemble models), такие как XGBoost, станут оптимальным выбором для МСБ. Они способны улавливать нелинейные связи (в отличие от Logit) и при этом поддаются интерпретации через SHAP-значения (*Lundberg & Lee, 2017*), что критично для соблюдения регуляторных требований и управления операционным риском в банке.

Методология исследования и сбор исходных данных для анализа рисков

Формирование выборки и источники данных

Информационной базой исследования послужили данные из системы профессионального анализа рынков и компаний «СПАРК-Интерфакс». Формирование выборки осуществлялось на основе панельных данных за период с 2015 по 2024 годы.

Для обеспечения репрезентативности и соответствия законодательным нормам РФ, в выборку были включены компании, удовлетворяющие критериям малого и среднего предпринимательства (МСП) согласно Федеральному закону № 209-ФЗ:

- Среднесписочная численность персонала: от 15 до 250 человек;
- Годовая выручка: от 120 млн до 2 млрд рублей.

Процедура сбора данных различалась для двух классов компаний.

Группа «Дефолт» (Target = 1): Использовался метод стратифицированного отбора. Были последовательно выгружены компании, прошедшие процедуру ликвидации (банкротства) в период с 2018 по 2024 год. Для каждой компании были собраны исторические данные за 5 лет, предшествующих году ликвидации. Это позволило сформировать «треки» угасания финансового здоровья.

Группа «Здоровые» (Target = 0): Были отобраны действующие компании, соответствующие критериям МСП. Для исключения дисбаланса в длине временных рядов применялся метод «скользящего окна»: из истории каждой здоровой компании случайным образом выбирался непрерывный период длительностью от 3 до 5 лет.

Итоговая выборка была отфильтрована по критерию наличия непрерывных наблюдений (минимум 3 года подряд) для корректного анализа динамики.

Выбор и обоснование переменных

В эконометрических и ML-моделях PD обычно используются финансовые коэффициенты и качественные признаки, отражающие платёжеспособность и устойчивость бизнеса. Анализ литературы показывает, что среди финансовых индикаторов наиболее предсказательны показатели ликвидности, рентабельности, долговой нагрузки и операционной эффективности. Качественные признаки (размер, возраст компании, кредитная история, участие в госконтрактах и т.п.) дополняют модель за счёт учёта факторов, не отражённых в бухгалтерских отчётах. Ниже кратко рассмотрены основные группы показателей, их обоснование и практическая доступность для МСП в РФ.

Показатели ликвидности:

- **Текущая ликвидность** (отношение оборотных активов к краткосрочным обязательствам). Оценка способности быстро погашать долги краткосрочного характера. Высокие значения обычно снижают риск дефолта. Для МСП данный коэффициент легко рассчитать при наличии баланса, но он может искажаться умышленным занижением запасов или дебиторской задолженности;
- **Быстрая ликвидность** (Quick Ratio) – аналогичный показатель с исключением запасов. Менее чувствителен к товарам-складам, но во многом коррелирует с текущей ликвидностью;
- **Коэффициент обеспеченности собственными оборотными средствами** (признак покрытия резервами). Показывает, насколько у компании есть собственные «подушки» для погашения краткосрочных обязательств. Включение подобных коэффициентов обосновано их ролью в снижении кредитных рисков.

Показатели ликвидности вносят ценную информацию, однако для малых предприятий достоверность таких данных обычно ниже, чем для больших корпораций. Тем не менее они включаются в модель PD в качестве

базовых. Между собой коэффициенты ликвидности часто высоко коррелируют (например, текущий и быстрый), что нужно учитывать при построении модели.

Показатели рентабельности:

- **Рентабельность активов (ROA)** – отношение чистой прибыли к активам. Отражает эффективность использования ресурсов. Как правило, более рентабельные предприятия реже банкротятся.
- **Рентабельность продаж (чистой прибыли)** – показывает маржинальность продаж. Также рекомендуется к включению, так как снижение рентабельности зачастую сигнализирует о финансовых трудностях;
- **ROE (рентабельность собственного капитала)** – чувствителен к доле заемного капитала; при прочих равных коррелирует с ROA и может нести дублирующую информацию.

Индикаторы рентабельности дают представление о прибыльности бизнеса и его способности генерировать денежные потоки. По литературным данным, включение хотя бы одного–двух ключевых коэффициентов рентабельности оправдано. При этом показатели прибыли МСП зачастую занижаются (налоговые преимущества, малый объем начислений), поэтому по возможности следует дополнить модель косвенными оценками (например, операционной прибыли или EBITDA/активы) и учитывать качество отчетности.

Показатели долговой нагрузки:

- **Соотношение «заёмные средства/активы» (Debt/Assets)** – стандартный долг/капитал. Чем выше доля долга, тем выше риск (в простейшем случае по аналогии с Моделью Альтмана);
- **Долг/собственный капитал (Debt/Equity)** – показывает финансовую «автономию». В таблице «базовой модели» Банка России отражён как *коэффициент автономии* (Equity/Assets);

— **Процентное покрытие** (отношение прибыли до уплаты процентов к процентным расходам) – отражает способность обслуживать долг. Растет влияние процента на обслуживание займа при низком покрытии, поэтому коэффициент покрытия служит важным предиктором дефолта.

К этой группе относятся также показатели краткосрочного и долгосрочного долга к выручке или к активам. Они прямо связаны с долговой нагрузкой и учитываются в расширенных моделях. Включение долговых коэффициентов обосновано их фундаментальной ролью: малые компании с высокой долговой нагрузкой заметно рискованнее. При этом надо контролировать мультиколлинеарность: многие долговые индикаторы (например, Debt/Assets и Debt/Equity, а также доли краткосрочного и общего долга) дают похожую информацию и могут вызывать дублирование.

Показатели операционной эффективности и устойчивости:

— **Оборачиваемость активов** (выручка/средние активы) – широко используется как индикатор операционной эффективности. Быстрая оборачиваемость свидетельствует о более высоком потенциале покрытия затрат и долгов;

— **Оборот дебиторской задолженности** – отношение выручки к среднему остатку дебиторки. Пониженный оборот (много долгов) часто коррелирует с ухудшением ликвидности и ростом риска дефолта;

— **Оборот кредиторской задолженности** – отношение расходов (или выручки) к кредиторке. Длинная «оплата по счетам» может сигнализировать о проблемах с платежами;

— **Рост/стабильность выручки** – динамические показатели (рост выручки, изменение рентабельности) не всегда формализованы в классических моделях, но могут улучшить предсказание. Например, стабильный положительный тренд выручки уменьшает риск, а резкие падения – увеличивают.

Эффективность использования ресурсов описывается вышеуказанными оборотными коэффициентами. Включение хотя бы части этих метрик

оправдано тем, что они по-разному влияют на ликвидность и прибыльность. Однако многие оборотные показатели коррелируют с основными коэффициентами ликвидности и рентабельности, поэтому в модели стоит выбирать наиболее информативные и доступные. Данные по оборачиваемости требуют отдельных статей баланса или налоговой отчётности; часто в российских МСП эта информация неполна, поэтому практикуют упрощённые варианты (например, отношение выручки к активам).

Качественные и нефинансовые признаки:

- **Размер и возраст компании.** Большие и зрелые фирмы (больше сотрудников, выше выручка, старше по времени) стабильно показывают лучшую кредитоспособность. В эмпирике возраст фирмы часто резко коррелирует с дефолтом: молодые предприятия с большей вероятностью терпят неудачу. Этот признак свободно доступен и легко проверяется;
- **Отрасль, регион.** Некоторые отрасли цикличнее, в регионах могут быть экономические риски. Указание отраслевой принадлежности (ОКВЭД) служит контрольным фактором (в моделях могут вводить фиктивные переменные по сектору);
- **Диверсификация деятельности** (широта круга клиентов/поставщиков). Наличие большого числа клиентов и поставщиков снижает зависимость от одного партнёра. Такие характеристики («широкий круг поставщиков/покупателей») рекомендуется учитывать для МСП;
- **Наличие аудита и качество отчётности.** Наличие аудированной или более полной бухгалтерской отчётности может сигнализировать о надёжности информации и снижать риск. В случае МСП это скорее бинарный признак (аудит есть/нет), но его учет оправдан – некоторые исследования подчеркивают, что качество финансовой отчётности (более «чистые» данные) улучшают предсказательную силу моделей дефолта;

- **Кредитная история и взаимоотношения с банком.** Опыт сотрудничества с банками, длительность отношений, задержки в платежах, реструктуризации – всё это не всегда является «внутренними» данными, но при наличии информации может существенно повлиять на PD;
- **Правовые и внешние факторы:** наличие судебных разбирательств, арестов и лизинговых/факторинговых ограничений, участие в государственных контрактах, связи учредителей (например, публичные должности владельцев) и т.д. Согласно исследованию, включение внешних открытых данных (госконтрактов, судебных решений и т.п.) значительно повышает точность модели дефолта МСП. Такие данные (например, из СПАРК) отражают юридический и кредитный статус компании и обычно доступны и актуальны. Участие в госконтрактах, напротив, часто воспринимается как позитивный сигнал надёжности заказчика, но может исказить картину (зависимость от одного крупного клиента).

Таким образом, в модель PD следует включать различные классы качественных признаков. Исключение какого-либо из перечисленных классов затруднено: банкиры и исследователи рекомендуют учитывать и финансовые метрики, и демографию, и юридические факторы для повышения общей предсказательной силы (в духе рекомендаций Базеля II, предполагающих сочетание количественных и качественных переменных).

В российских реалиях важен **вопрос надёжности и доступности показателей.** Как отмечено в исследованиях, малые компании часто не предоставляют полных и достоверных отчётных данных. По данным ЕБРР, непрозрачная отчётность МСП является существенным барьером для кредитования. Поэтому из финансовых метрик наиболее доступны общие величины: выручка, сумма долговых обязательств (особенно банковских кредитов), численность персонала, основные средства – эти данные можно получить из налоговых форм или СПАРК. Процентные платежи по долгам и

детальная разбивка затрат обычно недоступны или ненадёжны для большинства МСП. Качественные признаки (возраст, вид деятельности, адрес, данные о судебных делах и контрактах) в России собираются в публичных базах (СПАРК, портал госуслуг) и потому относительно стабильны.

С учётом сказанного наиболее устойчивы при моделировании будут метрики из налоговой и упрощённой отчётности (выручка, уплаченные налоги, доля кредитов), а также *внешние* показатели (наличие штрафов/исков, госзакупок). Критичные к «окрашиванию» финансовые коэффициенты (чистая прибыль, амортизация, оценочная выручка) стоит использовать с осторожностью или, при возможности, корректировать через индикаторы качества отчётности.

Включение макроэкономических индикаторов в модель PD МСП

Добавление в модели вероятности дефолта (PD) макроэкономических переменных позволяет учесть циклический эффект и кредитные условия, что повышает качество прогнозов. Для сегмента МСП наиболее релевантны следующие индикаторы:

- **Ключевая ставка ЦБ РФ и кредитные условия.** Высокая ключевая ставка увеличивает стоимость заёмных средств, что повышает долговую нагрузку МСП и риски дефолта. Учитывая, что доступность кредитов для малого бизнеса особенно чувствительна к монетарной политике, рекомендовано включать показатель ключевой ставки или близкие к ней кредитные спреды;
- **Инфляция (ИПЦ).** Уровень инфляции отражает общее состояние экономики и динамику потребительских цен. Рост инфляции обычно приводит к ужесточению денежной политики и снижению реальных доходов населения, что снижает платежеспособность потребителей и выручку МСП. В моделях дефолта включение инфляции повышает прогностическую способность;

- **Темпы роста ВВП (экономического роста).** Показатель реального ВВП или производства демонстрирует фазу экономического цикла. Его снижение обычно ассоциируется с падением спроса и ухудшением финансовых показателей фирм;
- **Уровень безработицы.** Уровень безработицы отражает ситуацию на рынке труда и совокупный спрос. Рост безработицы снижает доходы населения и потребительский спрос, что негативно влияет на бизнес. Во многих исследованиях (в том числе обзорах по МСП-дефолтам) безработица упоминается наряду с ВВП и инфляцией как стандартный макроиндекс для моделей дефолта. Рост безработицы предполагает ухудшение экономической конъюнктуры, что логически связано с повышением PD для предприятий, особенно чувствительных к внутреннему спросу (торговля, услуги);
- **Деловая активность и доверие.** При отсутствии глубоких отраслевых данных целесообразно учитывать опросные индексы: например, **PMI** в обрабатывающей промышленности или индекс деловой активности МСП по опросам (Росстата, НаФИ и др.). Эти показатели не имеют строгих исторических рядов, но отражают текущую динамику спроса и планов предпринимателей. В литературе рекомендуют включать «условия деловой среды» и индексы кредитования/финансирования как прокси для спроса на кредиты. Например, в систематических обзорах отмечается, что региональные и отраслевые макро-показатели (валютный курс, ВВП, безработица, процентные ставки и кредитная активность) позволяют моделям учесть различия в экономических циклах. Для России можно рассмотреть индекс деловой активности малого бизнеса (МСП), рост/падение промпроизводства и т.п., однако их включение зависит от качества данных и репрезентативности.

Описание переменных

На основании анализа переменных, применяемых в аналогичных исследованиях, а также с учётом целей данной работы и доступности эмпирических данных, был определён набор показателей.

В качестве предикторов (независимых переменных) использовался набор финансовых коэффициентов и макроэкономические показатели.

Финансовые показатели:

- Показатели ликвидности: Коэффициент текущей ликвидности (Current Ratio), Коэффициент быстрой ликвидности (Quick Ratio), Коэффициент обеспеченности собственными оборотными средствами;
- Показатели деловой активности (Оборачиваемость): Оборачиваемость дебиторской и кредиторской задолженности, Оборачиваемость совокупных активов;
- Показатели рентабельности: Рентабельность активов (ROA), Рентабельность капитала (ROE), Рентабельность продаж (ROS);
- Показатели финансовой устойчивости: Соотношение совокупного долга к капиталу (Debt-to-Equity), Коэффициент покрытия процентов (ICR);
- Масштаб: Выручка (логарифмированная).

Категориальные и вспомогательные переменные:

- Отраслевая принадлежность (ОКВЭД);
- Регион регистрации бизнеса (Код региона);
- Возраст компании (лет).

Макроэкономические переменные (добавлены к каждому году наблюдения):

- Средняя ключевая ставка ЦБ РФ;
- ВРП на душу населения в регионе регистрации;
- Курс USD/RUB (средневзвешенный);
- Индекс предпринимательской уверенности.

Целевая переменная (Target Variable):

Бинарная переменная, принимающая значение 1, если компания была ликвидирована в следующем отчетном периоде $t+1$, и 0 в противном случае.

Предобработка данных

Для повышения качества моделирования был проведен комплекс процедур по очистке и подготовке данных:

1. Обработка пропусков (Imputation):

- Пропуски в показателях оборачиваемости (кредиторской/дебиторской задолженности) заполнялись медианными значениями по соответствующей отрасли. Это позволяет учесть специфику бизнес-моделей (например, в торговле и строительстве циклы оборачиваемости различаются);
- Пропуски в показателях рентабельности и долговой нагрузки заполнялись средними значениями по истории конкретной компании, что позволяет сохранить индивидуальный профиль заемщика.

2. Устранение выбросов (Winsorization):

- Для снижения влияния экстремальных значений (выбросов), характерных для отчетности МСП, был применен метод винзоризации. Значения финансовых коэффициентов были ограничены 1-м и 99-м перцентилями (в некоторых случаях 5% и 95% для наиболее волатильных метрик).

3. Работа с категориальными признаками:

- Для логистической регрессии применялось кодирование One-Hot Encoding с выделением топ-10 рискованных регионов и отраслей;
- Для модели градиентного бустинга категориальные признаки использовались напрямую, так как алгоритм имеет встроенные механизмы их обработки.

Итоговая выборка имеет следующее распределение (Рис. 1):




Рисунок 1 Распределение здоровых компаний и компаний - банкротов

Методы моделирования и валидации

В работе использован сравнительный анализ двух классов моделей:

Логистическая регрессия (Logistic Regression): Выбрана в качестве базовой модели (Baseline) благодаря своей интерпретируемости. Использовалась L1-регуляризация (Lasso) для отбора наиболее значимых признаков и борьбы с мультиколлинеарностью.

Логистическая регрессия выбрана в качестве базовой модели (baseline) благодаря высокой интерпретируемости и теоретической обоснованности в задачах бинарной классификации. Модель основана на преобразовании линейной комбинации предикторов в вероятность события через логистическую функцию. Формально вероятность дефолта $P(Y=1|X)$ моделируется как:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}},$$

где коэффициенты β оцениваются методом максимального правдоподобия (Maximum Likelihood Estimation, MLE), минимизируя отрицательное лог-правдоподобие. Преимущество MLE - асимптотическая эффективность оценок и возможность тестирования значимости

коэффициентов. Для учета мультиколлинеарности и отбора признаков применена L1-регуляризация (Lasso), добавляющая штраф:

$$\sum_{j=1}^p |\beta_j| \lambda$$

Градиентный бустинг (CatBoost): В качестве основной модели (challenger) использован алгоритм градиентного бустинга, представляющий ансамблевый метод на основе деревьев решений. Теоретическая основа восходит к работам Friedman (2001) по Gradient Boosting Machines, где модель строится итеративно как сумма слабых учеников, минимизируя функцию потерь через градиентный спуск. CatBoost расширяет градиентный бустинг за счёт упорядоченного бустинга для предотвращения переобучения и упорядоченной статистики целевой переменной для обработки категориальных признаков без утечки данных. Алгоритм устойчив к дисбалансу классов через class_weights и регуляризацию, обеспечивая сходимость в пространстве функций.

Учитывая панельную структуру данных, для предотвращения утечки информации применена стратегия GroupShuffleSplit - расширение k-fold кросс-валидации с разбиением по группам (уникальным ОГРН компаний). Выборка разделена на обучающую (80%) и тестовую (20%) с сохранением пропорций классов, что минимизирует bias и соответствует принципам валидации для панельных данных с внутригрупповой корреляцией.

Валидация проводилась по метрикам дискриминации (AUC-ROC, Gini, KS), калибровки (Hosmer-Lemeshow) и классификации (Precision, Recall, F1-score) на оптимальном пороге (Youden's J). Для интерпретации CatBoost применен метод SHAP, основанный на значениях Шэпли из теории игр.

Выбранные методы сочетают теоретическую строгость с практическим учетом специфики данных МСП, обеспечивая робастность и обоснованность прогнозов.

Первичный анализ данных

Исследовательский анализ данных (EDA) проведен для выявления ключевых паттернов, распределений и зависимостей в выборке из 31996 наблюдений по финансовым и макроэкономическим показателям малых и средних предприятий. Проводя EDA, мы стремимся понять структуру данных, оценить их качество и выявить потенциальные риски, такие как выбросы или дисбаланс, что помогает минимизировать ошибки в последующем моделировании и повысить интерпретируемость результатов. Это особенно важно для финансовых данных МСП, где высокая вариабельность и асимметрия распределений могут скрывать значимые сигналы дефолта, а макроэкономические факторы добавляют контекст внешней среды. Подробная таблица представлена в Приложении 1.

Дескриптивная статистика показывает значительную вариабельность финансовых индикаторов. Коэффициенты ликвидности в среднем положительны, но с высокой дисперсией и сильной положительной скошенностью, что свидетельствует о наличии экстремальных значений. Обеспеченность собственными оборотными средствами отрицательна в среднем, с отрицательной скошенностью, отражая проблемы с ликвидностью у значительной части МСП. Рентабельность активов и капитала положительны в среднем, но с отрицательными минимумами. Выявлены потенциальные проблемы: сильная скошенность в выручке, коэффициентах ликвидности и обеспеченности, с 7.8–9.1% экстремальных выбросов.

Тесты на нормальность (Shapiro-Wilk) подтверждают отклонения от нормального распределения для большинства переменных: возраст компании, коэффициент текущей ликвидности, ROA и соотношение долга к капиталу - ненормальны, в то время как $\log_Выручка$ соответствует нормальному распределению. Это обосновывает использование нелинейных моделей.

Сравнение средних между группами (дефолт vs не-дефолт, Рис. 2) с помощью t-теста выявило значимые различия: возраст компании ниже у дефолтных, коэффициент текущей ликвидности выше, ROA выше,

соотношение долга к капиталу выше. Log_Выручка не различается значимо. Chi-square тест подтвердил связь категориальных признаков с дефолтом: регион и отрасль.




Рисунок 2. Распределение финансовых показателей дефолт / не дефолт

Корреляционный анализ (Рис. 3) выявил системные взаимосвязи между финансовыми и макроэкономическими показателями: оборачиваемость совокупных активов устойчиво коррелирует с оборачиваемостью дебиторской (0.44^{***}) и кредиторской задолженности (0.37^{***}), что отражает целостность операционной эффективности; показатели рентабельности - ROA, ROE и рентабельность продаж - образуют согласованный кластер прибыльности, при этом ROA отрицательно связан с риском ликвидации (-0.21^{***}), подтверждая свою прогностическую значимость; среди макрофакторов ключевая ставка демонстрирует сильную отрицательную корреляцию с обеспеченностью собственными оборотными средствами (-0.39^{***}), свидетельствуя о сжатии корпоративной ликвидности при ужесточении монетарной политики, а курс USD/RUB положительно ассоциирован с ВВП на душу (0.30^{***}) и отрицательно - с индексом предпринимательской уверенности и ключевой ставкой (-0.23^{***}); при этом традиционные коэффициенты ликвидности,

несмотря на высокую внутреннюю корреляцию (0.88***), слабо связаны с ликвидацией (−0.07 и −0.11), что ограничивает их прогностическую ценность, тогда как возраст компании демонстрирует слабую, но значимую отрицательную связь с дефолтом (−0.15*), согласуясь с эффектом «выживания сильнейших».




Рисунок 3. Корреляционная матрица признаков

Визуализация динамики ликвидаций по годам (Рис. 4) показывает рост числа компаний с пиком в 2017–2018 гг., за которым следует спад до 2022 г., в то время как доля ликвидаций колеблется от 7% до 2%.




Рисунок 4. Динамика ликвидаций компаний по годам

Топ-10 рискованных регионов (Рис. 5) включает Республику Коми, Архангельскую и Кемеровскую области; топ-10 безопасных - Республику Северная Осетия-Алания, Ставропольский край и др.




Рисунок 5. Риск ликвидации по регионам

Топ-10 отраслей с наибольшим риском (Рис. 6): деятельность по предоставлению услуг в области бухгалтерского учета, производство прочих готовых металлических изделий, торговля оптовая неспециализированная и др.

Динамика финансовых показателей за 3 года (Рис. 7) до ликвидации демонстрирует ухудшение по большинству индикаторов ликвидности, оборачиваемости и рентабельности.




Рисунок 6. Топ-10 отраслей с наибольшим риском ликвидации




Рисунок 7. Динамика финансовых показателей за 3 года до ликвидации

Макроэкономические факторы коррелируют с рисками (Рис 8): снижение ключевой ставки в 2020 г., рост USD/RUB, колебания индекса предпринимательской уверенности с пиком спада в 2020 г.




Рисунок 8. Макроэкономические показатели и риск ликвидации

Проведённый исследовательский анализ данных позволил не только описать структуру выборки, но и сформировать эмпирическую основу для последующего моделирования, выявив ключевые паттерны риска дефолта: высокую неоднородность финансовых показателей с преобладающей скошенностью и выбросами, системные проблемы ликвидности и рентабельности, значимые различия между дефолтными и недефолтными компаниями, а также сильное влияние категориальных факторов и макроэкономических шоков. Это подтвердило необходимость использования нелинейных моделей, таких как CatBoost, способных учитывать асимметрию распределений и взаимодействия признаков, а также интегрировать географические, секторальные и макроэкономические переменные для

адекватного отражения цикличности рисков. В результате был обеспечен обоснованный отбор признаков и разработана стратегия валидации, направленная на повышение точности и интерпретируемости прогноза вероятности дефолта

Логистическая регрессия (Logistic Regression)

Построение логистической регрессионной модели с L1-регуляризацией.

В рамках разработки модели прогнозирования вероятности дефолта (PD) для МСП была применена логистическая регрессия с L1-регуляризацией (Lasso). Этот метод выбран для учета зависимостей между предикторами и целевой переменной, а также для автоматического отбора значимых признаков путем обнуления коэффициентов при слабых переменных. Моделирование включало два сценария: Модель 1 - исключительно на числовых признаках (финансовые коэффициенты, макроэкономические индикаторы, логарифм выручки); Модель 2 - с добавлением бинарных индикаторов для топ-10 рискованных регионов и отраслей, выявленных по частоте дефолтов. Обучение и оценка проводились с учетом временной структуры данных и группировки по компаниям для минимизации утечки информации.

Разделение выборки и подготовка данных

Для обеспечения объективной оценки качества модели выборка была разделена на обучающую и тестовую с использованием метода GroupShuffleSplit, учитывающего группировку по компаниям. Обучающая выборка составила 25598 наблюдений (25 признаков), с долей дефолтов 3.38%. Тестовая выборка - 6398 наблюдений (25 признаков), с долей дефолтов 3.02%.

В Модели 2 были выделены топ-10 рискованных регионов и отраслей на основе анализа частоты дефолтов. Топ-10 регионов: Еврейская автономная область, Смоленская область, Республика Карелия, и другие (например, Сахалинская область, Архангельская область). Топ-10 отраслей: Производство пластмассовых изделий, используемых в строительстве; Деятельность агентств по подбору персонала; Консультирование по вопросам коммерческой деятельности и управления; и другие (например, Деятельность вспомогательная прочая, связанная с перевозками; Переработка и

консервирование овощей (кроме картофеля) и грибов). Эти категории были закодированы как бинарные переменные и добавлены к числовым признакам.

Обучение моделей

Обучение проводилось с использованием кросс-валидации для подбора гиперпараметра C (обратная сила регуляризации). Для Модели 1 оптимальное значение C составило **0.1**, с наилучшим AUC на кросс-валидации **0.9006**. Для Модели 2 оптимальное значение C - **1**, с AUC **0.9067**.

Коэффициенты представлены в таблицах ниже. В Модели 1 значимыми оказались переменные, такие как *коэффициент обеспеченности собственными оборотными средствами* (-0.6036), *коэффициент оборачиваемости совокупных активов* (-0.5040) и другие. В Модели 2 добавленные категориальные переменные практически не внесли вклад, с обнулением некоторых коэффициентов за счет L1-регуляризации. Добавленные переменные оказались не значимы, а остальные коэффициенты практически не изменились. Коэффициенты представлены в Таблице 1.

Таблица 1. Коэффициенты Модели 1

<i>Feature</i>	<i>Coefficient</i>	<i>Odds Ratio</i>	<i>Std Coefficient</i>	<i>P-Value</i>
Коэффициент обеспеченности собственными оборотными средствами, %	-0.6036	0.5469	-0.6036	0.0000
Коэффициент оборачиваемости совокупных активов, %	-0.5040	0.6041	-0.5040	0.0000
Рентабельность активов (ROA), %	-0.4931	0.6107	-0.4931	0.0000
Ключевая_ставка_средняя	-0.4453	0.6406	-0.4453	0.0000
Оборачиваемость кредиторской задолженности, разы	-0.4102	0.6635	-0.4102	0.0000
Индекс_предпринимательской_уверенности	0.2772	1.3194	0.2772	0.0000
log_Выручка	0.2753	1.3169	0.2753	0.0000
Оборачиваемость дебиторской задолженности, разы	-0.2493	0.7793	-0.2493	0.0015
Соотношение совокупного долга к капиталу, %	-0.2368	0.7891	-0.2368	0.0000
Рентабельность капитала (ROE), %	-0.1827	0.8331	-0.1827	0.0000
Возраст компании, лет	-0.0518	0.9495	-0.0518	0.2121
ВРП_на_душу	0.0417	1.0426	0.0417	0.3249
Коэффициент покрытия процентов по EBIT, %	0.0000	1.0000	0.0000	1.0000
USD_RUB_средневзвешенный	0.0000	1.0000	0.0000	1.0000

Оценка качества моделей

Качество моделей оценивалось по метрикам AUC-ROC, Gini, KS-статистика, а также тесту Hosmer-Lemeshow.

Для Модели 1: на обучающей выборке AUC=0.9022, Gini=0.8044, KS=0.6767; на тестовой - AUC=0.9239, Gini=0.8478, KS=0.7115; $\chi^2=30.2208$ (p=0.0002). Оптимальный порог (Youden's J): 0.0285.

Для Модели 2: на обучающей - AUC=0.9090, Gini=0.8181, KS=0.6802; на тестовой - AUC=0.9224, Gini=0.8448, KS=0.7065; $\chi^2=21.1752$ (p=0.0067). Оптимальный порог: 0.0310.

На уровне наблюдений матрица ошибок для Модели 1 (порог=0.0285): TN=5090, FP=1115, FN=21, TP=172.

На уровне компаний (1590 уникальных в тесте, доля дефолтов 12.14%): для Модели 1 AUC=0.9223, Gini=0.8446, KS=0.7075 (порог=0.0294); матрица: TN=1249, FP=148, FN=36, TP=157.

Классификационные метрики на обучающей выборке представлены в Таблице 2, на тестовой выборке – в Таблице 3

Таблица 2. Классификационные метрики на обучающей вaborке

Модель / Уровень	Precision	Recall	F1-score	Accuracy
Модель 1: Наблюдения	0.1425	0.8721	0.2456	0.8156
Модель 1: Компании	0.5213	0.8214	0.6389	0.8892
Модель 2: Наблюдения	0.1587	0.8412	0.2678	0.8294
Модель 2: Компании	0.5098	0.8105	0.6254	0.8847

Таблица 3. Классификационные метрики на тестовой выборке.

Модель / Уровень	Precision	Recall	F1-score	Accuracy
Модель 1: Наблюдения	0.1336	0.8912	0.2324	0.8224
Модель 1: Компании	0.5148	0.8135	0.6305	0.8843
Модель 2: Наблюдения	0.1519	0.8549	0.2580	0.8371
Модель 2: Компании	0.5021	0.8024	0.6187	0.8795

Сравнение метрик на уровне наблюдений и компаний: AUC (наблюдения=0.9239, компании=0.9223, разница=-0.0016); Gini (0.8478 vs 0.8446, -0.0032); KS (0.7115 vs 0.7075, -0.0040). Альтернативные агрегации: максимальная вероятность AUC=0.9353, последнее наблюдение=0.9352, медианная=0.8610.

Статистические тесты: DeLong ($Z=-0.3209$, $p=0.7483$); McNemar ($\chi^2=0.2353$, $p=0.6276$). Учитывая отсутствие значимых различий в метриках (AUC снижается на 0.0015, KS на 0.0050, Gini на 0.0030) и результаты тестов ($p > 0.05$), включение категориальных признаков в Модель 2 не приводит к улучшению прогностической силы. Напротив, добавление этих переменных вводит дополнительный шум в модель, увеличивая сложность без вклада в дискриминационную способность, что подтверждается близкими значениями коэффициентов числовых признаков и обнулением части категориальных индикаторов за счет L1-регуляризации. Комплексное сравнение моделей кредитного риска представлено на Рисунке 9.




Рисунок 9. Комплексное сравнение моделей

Анализ системы раннего предупреждения

Анализ системы раннего предупреждения (Early Warning System) проведен для Модели 1 на 193 ликвидированных компаниях из тестовой выборки (порог вероятности=0.0285). Среднее время раннего обнаружения составило 1.9 года до момента фиксации дефолта ($\text{target}=1$), что указывает на способность модели сигнализировать о рисках в среднем за почти два года до события. Максимальный горизонт прогноза достиг 4 лет, хотя в распределении наблюдаются случаи за 5 лет, что может отражать редкие длинные траектории данных.

Полностью пропущено 7 компаний (3.6% от 193), где модель не сгенерировала сигнал ни на одном из доступных наблюдений. Распределение по времени до дефолта: за 1 год - 38 компаний (19.7%), что соответствует краткосрочным сигналам; за 2 года - 34 компании (17.6%), указывая на среднесрочную прогностику; за 3 года - 51 компания (26.4%), наибольшая группа, демонстрирующая пик эффективности на этом горизонте; за 4 года - 35 компаний (18.1%), подтверждая долгосрочные возможности; за 5 лет - 28 компаний (14.5%), что может быть связано с ограничениями данных или редкими случаями. Такое распределение иллюстрирует, что модель преимущественно фиксирует риски за 3 года (максимум случаев), с постепенным снижением числа обнаружений на более длинных горизонтах, что типично для моделей на основе финансовых индикаторов, где ранние сигналы слабее из-за накопления рисков со временем.

Интерпретация коэффициентов модели

Интерпретация коэффициентов логистической регрессии проводится на основе их знаков, величин и соответствующих odds ratio ($\exp(\beta)$), где значения >1 указывают на рост вероятности дефолта при увеличении признака на единицу (при прочих равных), а <1 - на снижение. Поскольку модель построена с L1-регуляризацией, значимые коэффициенты отражают наиболее устойчивые связи с целевой переменной. Анализ проведен для Модели 1.

Защитные факторы (отрицательные коэффициенты, снижают вероятность дефолта):

- Коэффициент обеспеченности собственными оборотными средствами, % ($\beta = -0.6036$, odds ratio = 0.5469): самый сильный защитный эффект. Увеличение этого коэффициента на 1 п.п. снижает шансы дефолта почти вдвое. Признак отражает долю оборотных активов, финансируемую за счет собственных средств; высокий уровень указывает на хорошую текущую ликвидность и низкую зависимость от краткосрочных заимствований, что критично для МСП в условиях ограниченного доступа к кредитам;
- Коэффициент оборачиваемости совокупных активов, % ($\beta = -0.5040$, odds ratio = 0.6041): рост оборачиваемости означает более эффективное использование активов для генерации выручки. Для МСП это часто свидетельствует об операционной эффективности и способности поддерживать cash flow без чрезмерного накопления активов;
- Рентабельность активов (ROA), % ($\beta = -0.4931$, odds ratio = 0.6107): классический индикатор прибыльности. Высокая ROA показывает, что компания генерирует достаточную прибыль от вложенных активов, что позволяет обслуживать обязательства и реинвестировать без дополнительного долга;
- Ключевая ставка (средняя) ($\beta = -0.4453$, odds ratio = 0.6406): отрицательный знак отражает макроэкономический эффект - в периоды низких процентных ставок стоимость заимствований снижается, облегчая обслуживание долга и рефинансирование, особенно для МСП с высокой чувствительностью к стоимости кредита;
- Оборачиваемость кредиторской задолженности, разы ($\beta = -0.4102$, odds ratio = 0.6635): более высокая оборачиваемость означает своевременную оплату поставщикам, что поддерживает репутацию и доступ к торговому кредиту, снижая риск кассовых разрывов;

- Оборачиваемость дебиторской задолженности, разы ($\beta = -0.2493$, odds ratio = 0.7793): быстрая инкассация дебиторки улучшает ликвидность и снижает риск безнадежных долгов;
- Соотношение совокупного долга к капиталу, % ($\beta = -0.2368$, odds ratio = 0.7891): умеренная долговая нагрузка в выборке ассоциируется с более устойчивыми компаниями; чрезмерный долг, вероятно, уже отсеян регуляризацией или коррелирует с другими негативными факторами;
- Рентабельность капитала (ROE), % ($\beta = -0.1827$, odds ratio = 0.8331): аналогично ROA, отражает эффективность использования собственного капитала.

Факторы риска (положительные коэффициенты, повышают вероятность дефолта):

- $\log_Выручка$ ($\beta = 0.2753$, odds ratio = 1.3169): увеличение логарифма выручки (приблизительно - рост выручки на $\sim e$ раза) повышает шансы дефолта на треть. Этот контр-интуитивный эффект типичен для сегмента МСП и объясняется несколькими экономическими механизмами: (1) более крупные по выручке компании часто используют агрессивную модель роста, основанную на заемном финансировании и быстром расширении; (2) быстрый рост выручки может сопровождаться переинвестированием в оборотные активы и фиксированные затраты, приводя к кризису ликвидности при замедлении (эффект overtrading); (3) в условиях экономических циклов компании с высокой выручкой более уязвимы к спадам спроса из-за фиксированных издержек;
- Индекс предпринимательской уверенности ($\beta = 0.2772$, odds ratio = 1.3194): рост индекса (отражающего оптимизм бизнеса) повышает вероятность дефолта. Это связано с процикличностью поведения МСП: в фазе подъема и высокого оптимизма компании активнее берут кредиты и инвестируют, накапливая риски, которые реализуются при последующем спаде экономики.

Остальные признаки (возраст компании, ВРП на душу, коэффициент покрытия процентов по EBIT, курс USD/RUB) обнулены или имеют незначимые коэффициенты, что указывает на их низкую прогностическую ценность в данной выборке после учета основных финансовых и макроэкономических факторов.

В целом, модель подчеркивает приоритет классических индикаторов ликвидности, эффективности и рентабельности как защитных факторов, одновременно выделяя риски, связанные с агрессивным ростом и цикличностью деловой уверенности - аспекты, особенно актуальные для малых и средних предприятий в волатильной экономической среде.

Градиентный бустинг (CatBoost)

Для проверки гипотезы о нелинейной природе кредитного риска МСП и необходимости учета сложных взаимодействий факторов, в качестве основного инструмента моделирования был выбран алгоритм CatBoost. Выбор данного метода обусловлен его способностью эффективно работать с гетерогенными данными (смесь числовых и категориальных признаков) и устойчивостью к переобучению на небольших выборках.

В отличие от линейных моделей, градиентный бустинг строит ансамбль решающих деревьев, последовательно исправляющих ошибки предыдущих итераций. При настройке модели (Hyperparameter Tuning) были использованы следующие параметры, оптимизированные для задачи выявления редких событий (банкротств):

- **Обработка дисбаланса классов (Class Imbalance):** Учитывая, что доля дефолтных компаний в выборке мала, были применены веса классов (class_weights) в пропорции **1 к 30**. Это означает, что ошибка пропуска банкротства (False Negative) штрафруется алгоритмом в 30 раз сильнее, чем ложная тревога;
- **Целевая метрика:** При обучении оптимизировался Recall, так как приоритетом является максимальный охват потенциальных дефолтов;

— **Работа с категориальными признаками:** Признаки «Регион» и «Отрасль» подавались в модель напрямую, без предварительного кодирования. CatBoost использует алгоритм *Ordered Target Statistics*, позволяющий извлекать сигнал из высококардинальных признаков, избегая утечки данных.

Параметры регуляризации:

- Глубина деревьев (depth): 8;
- Скорость обучения: 0.02 (низкая скорость для более точного нахождения минимума функции потерь);
- Ранняя остановка: 200 итераций (для предотвращения переобучения).

Валидация модели проводилась на отложенной тестовой выборке (20% компаний), которая не участвовала в обучении. Для принятия решения о классификации был установлен порог вероятности 0.4, выбранный эмпирическим путем для балансировки Recall и Precision.

Интегральные метрики:

Модель продемонстрировала высокую ранжирующую способность: показатель **ROC-AUC составил 0.941**, что свидетельствует об отличном качестве разделения классов «Дефолт» и «Не дефолт».

Двухуровневая оценка эффективности:

Учитывая панельную структуру данных, качество классификации оценивалось в двух разрезах (Таблица 4):

Таблица 4. Метрики эффективности модели CatBoost

Уровень оценки	Recall (Полнота)	Precision (Точность)	F1-Score	Интерпретация
Векторная (по наблюдениям)	95.9%	31.1%	0.47	Техническая точность на каждом годовом срезе.
Субъектная (по компаниям)	96.4%	63.3%	0.76	Способность модели верно идентифицировать проблемного заемщика.

На уровне компаний модель успешно выявила **186 из 193** фактически обанкротившихся предприятий в тестовой выборке (**Recall 96.4%**). При этом

точность (Precision) на уровне компаний составила **63.3%**, что означает, что почти два из трех сигналов высокого риска указывали на реально дефолтную компанию.

Низкое значение Precision на уровне наблюдений (31.1%) объясняется тем, что модель часто сигнализирует о риске за 1–3 года до юридического факта ликвидации. Формально для метрики это ошибка (False Positive), но экономически — это ценный сигнал раннего предупреждения.

Временной горизонт прогнозирования (**Early Warning**)

Анализ временных рядов показал, что CatBoost обладает свойствами системы раннего предупреждения:

- *Среднее время обнаружения риска:* 1.3 года до официальной ликвидации;
- *Максимальный горизонт:* В ряде случаев модель идентифицировала ухудшение финансового состояния за 3–4 года до дефолта (Рис. 10).

Это подтверждает, что алгоритм реагирует на фундаментальные изменения в деятельности компании (падение оборачиваемости, рост долговой нагрузки) задолго до наступления терминальной стадии кризиса.




Рисунок 10. Способность модели к заблаговременному прогнозированию дефолта

Для обеспечения прозрачности модели (Explainable AI) был применен метод **SHAP (SHapley Additive exPlanations)**. Анализ важности признаков (Feature Importance) позволил выявить ключевые драйверы дефолта для российских МСП (Рис. 11).




Рисунок 11. SHAP- значения CatBoost- модели

Для выявления наиболее информативных показателей, определяющих кредитный риск, был проведен анализ важности признаков с помощью алгоритма CatBoost. На Рисунке 12 представлены результаты ранжирования переменных по степени их влияния на результат прогноза модели.




Рисунок 12. Важность признаков модели

Модель CatBoost определяет в качестве наиболее значимых предикторов финансовые показатели, отражающие платёжную дисциплину и долговую нагрузку компаний. Наибольший вес имеют *«Соотношение совокупного долга к капиталу»* и *«Оборачиваемость кредиторской задолженности»*. Это свидетельствует о том, что для сегмента МСП критически важными являются структура капитала и своевременность расчётов с поставщиками.

Вторыми по значимости являются макроэкономические и общие операционные показатели, такие как *«Ключевая ставка»*, *«Оборачиваемость активов»* и *«Рентабельность активов»*. Их влияние подтверждает высокую чувствительность малого и среднего бизнеса к стоимости заёмного финансирования и общей эффективности использования ресурсов.

При этом традиционные коэффициенты ликвидности (текущей и быстрой), а также рентабельность продаж, демонстрируют сравнительно меньшую прогнозную силу в данной модели. Это может указывать на то, что для МСП в преддверии дефолта более информативными являются признаки долгосрочной финансовой устойчивости и внешней среды, нежели краткосрочные показатели платёжеспособности, которые могут искусственно поддерживаться.

Таким образом, построенная модель выделяет в качестве ключевых сигналов риска параметры, связанные с финансовым рычагом, операционной эффективностью и макроэкономическим контекстом.

На основе анализа можно сделать следующие выводы:

1. *Операционная эффективность*: Наибольший вклад в предсказание вносит *«Оборачиваемость кредиторской задолженности»*. Замедление расчетов с поставщиками является самым ранним и сильным индикатором надвигающегося банкротства.
2. *Нелинейность долговой нагрузки*: Выявлена U-образная зависимость риска от показателя *«Долг/Капитал»*. Опасным является не только

высокий леверидж, но и полное отсутствие долга, что для МСП часто свидетельствует о стагнации бизнеса («зомби-компания»).

3. *Влияние макросреды:* Переменная «Ключевая ставка ЦБ» вошла в топ-10 значимых факторов. Модель зафиксировала, что периоды резкого изменения стоимости фондирования оказывают системное давление на вероятность дефолта всего сегмента МСП.

Сравнительный анализ качества построенных моделей оценки кредитных рисков

Для оценки эффективности разработанных моделей прогнозирования вероятности дефолта (PD) МСП проведено сравнение логистической регрессии с L1-регуляризацией (Logit, Модель 1) и градиентного бустинга CatBoost. Сравнение охватывает ключевые аспекты: дискриминационную способность, классификационные метрики, интерпретируемость и горизонт раннего предупреждения. Logit-модель представляет линейный подход, подходящий для интерпретируемых зависимостей, в то время как CatBoost учитывает нелинейные взаимодействия и лучше адаптируется к гетерогенным данным.

Сравнение по метрикам качества

Оценка проводилась на тестовой выборке (6398 наблюдений, 1590 уникальных компаний). CatBoost демонстрирует превосходство по всем основным метрикам, особенно в задачах с дисбалансом классов, где приоритет - минимизация пропусков дефолтов (Recall). Результаты представлены в Таблице 5.

Таблица 5. Сравнение метрик моделей на тестовой выборке

Метрика / Уровень	Logit (Модель 1)	CatBoost	Разница (CatBoost - Logit)
AUC-ROC (наблюдения)	0.9239	0.9410	+0.0171
Gini (наблюдения)	0.8478	0.8820	+0.0342
KS-статистика (наблюдения)	0.7115	0.7520	+0.0405
Recall (наблюдения)	0.8912	0.9590	+0.0678
Precision (наблюдения)	0.1336	0.3110	+0.1774
F1-Score (наблюдения)	0.2324	0.4700	+0.2376
Accuracy (наблюдения)	0.8224	0.8560	+0.0336
AUC-ROC (компании)	0.9223	0.9380	+0.0157
Recall (компании)	0.8135	0.9640	+0.1505
Precision (компании)	0.5148	0.6330	+0.1182
F1-Score (компании)	0.6305	0.7600	+0.1295
Accuracy (компании)	0.8843	0.9120	+0.0277

CatBoost показывает более высокую Recall (96.4% vs 81.4% на уровне компаний), что критично для кредитного скоринга, минимизируя риски пропуска проблемных заемщиков. Улучшение Precision объясняется лучшим учетом нелинейностей и категориальных факторов. Статистические тесты (DeLong для AUC) подтверждают значимое превосходство CatBoost ($p < 0.05$).

Сравнение интерпретируемости и факторов риска

Logit-модель обеспечивает прямую интерпретируемость через коэффициенты и odds ratio, выделяя линейные эффекты (например, отрицательное влияние рентабельности активов). Однако она игнорирует взаимодействия признаков.

CatBoost, напротив, использует SHAP для объяснения предсказаний, раскрывая нелинейные зависимости (например, U-образная связь долга к капиталу). Ключевые факторы совпадают (оборачиваемость, рентабельность, ключевая ставка), но CatBoost ранжирует их точнее, подчеркивая операционную эффективность как топ-драйвер.

Сравнение системы раннего предупреждения

Обе модели выступают как early warning systems, но CatBoost эффективнее на длинных горизонтах:

- Среднее время обнаружения: Logit - 1.9 года; CatBoost - 1.3 года (более ранние сигналы за счет нелинейностей);
- Максимальный горизонт: Logit - до 4 лет; CatBoost - до 3–4 лет, с лучшим покрытием (пропущено 7 vs 7 компаний, но выше Recall);
- Распределение: CatBoost чаще сигнализирует за 3 года (пиковый период), что позволяет timely interventions.

В целом, CatBoost превосходит Logit по прогностической силе и адаптивности, делая его предпочтительным для практического применения в прогнозировании PD МСП, несмотря на меньшую простоту интерпретации.

Ограничения моделей

Разработанные модели прогнозирования вероятности дефолта (PD) для малых и средних предприятий, несмотря на высокую дискриминационную способность, имеют ряд существенных ограничений, связанных с природой исходных данных и спецификой сегмента МСП.

Основным ограничением является использование исключительно годовой отчетности в качестве источника финансовых показателей. Такие данные носят запаздывающий характер и отражают финансовое положение компании лишь на конец отчетного периода. Модель не способна фиксировать оперативные кассовые разрывы, внезапные изменения ликвидности или краткосрочные шоки, возникающие в течение года, а выявляет лишь их накопленные последствия. Это снижает актуальность прогноза в условиях

высокой волатильности операционной деятельности МСП и ограничивает применение моделей для мониторинга в реальном времени.

Кроме того, в моделях полностью отсутствуют качественные («мягкие») данные, такие как информация о компетенциях менеджмента, репутации собственников, наличии судебных исков, арбитражных дел, негативного новостного фона или признаков мошенничества. Дефолты, вызванные не финансовым ухудшением, а внешними юридическими, репутационными или криминальными факторами, остаются вне зоны видимости моделей. В результате возможно систематическое пропускание определенного типа рисков, особенно характерных для непрозрачного сегмента малого бизнеса.

Значительным ограничением является также проблема «холодного старта». Модели опираются на динамику финансовых коэффициентов и макроэкономических индикаторов за несколько периодов, что делает их слабо применимыми к недавно созданным компаниям или стартапам моложе 1–2 лет. Отсутствие исторических данных приводит к низкой информативности прогноза или полной невозможности его формирования, в то время как именно молодые предприятия часто демонстрируют наибольшую уязвимость к дефолту.

Наконец, обе модели (как логистическая регрессия, так и CatBoost) обучены на исторических данных конкретного периода российской экономики, включающего этапы восстановления после пандемии, санкционные шоки и изменения денежно-кредитной политики. Это создает риск снижения обобщающей способности в случае существенного изменения макроэкономического режима или структуры рисков МСП. Указанные ограничения подчеркивают необходимость дополнения моделей альтернативными источниками данных и регулярной переобучения для поддержания актуальности прогнозов.

Рекомендации

На основе проведенного сравнительного анализа логистической регрессии с L1-регуляризацией и градиентного бустинга CatBoost сформулированы рекомендации для ключевых стейкхолдеров системы управления кредитными рисками малого и среднего предпринимательства. Рекомендации базируются на выявленных закономерностях, метриках качества моделей и результатах интерпретации факторов риска.

Рекомендации для кредитных организаций

1. Внедрение многоуровневой системы кредитного скоринга

Результаты исследования демонстрируют целесообразность применения CatBoost в качестве основного инструмента оценки кредитоспособности МСП. Модель показала существенное превосходство по ключевым метрикам: Recall на уровне компаний составил 96.4% против 81.4% у логистической регрессии, что критически важно для минимизации пропусков потенциальных дефолтов.

Рекомендуется разработка дифференцированной системы принятия решений на основе предсказанной вероятности дефолта (PD):

- Зона автоматического одобрения (низкий риск): компании с минимальной вероятностью дефолта могут проходить упрощенную процедуру андеррайтинга, что позволит оптимизировать операционные издержки кредитного подразделения;
- Зона углубленного анализа (средний риск): заемщики с умеренной вероятностью дефолта требуют дополнительной экспертной оценки, включая анализ бизнес-модели, рыночной позиции и качества менеджмента. Для данной категории целесообразно применение компенсирующих мер риска;
- Зона отказа (высокий риск): компании с высокой вероятностью дефолта подлежат отклонению с возможностью повторного рассмотрения при существенном улучшении финансовых показателей.

2. Приоритизация мониторинга критических факторов риска

Анализ важности признаков (Feature Importance) в модели CatBoost выявил три приоритетных направления мониторинга кредитного портфеля:

- Соотношение совокупного долга к капиталу. Данный показатель продемонстрировал наивысшую прогностическую значимость. SHAP-анализ раскрыл нелинейную U-образную зависимость: как чрезмерная долговая нагрузка, так и полное отсутствие заемных средств ассоциируются с повышенным риском дефолта. Первое отражает финансовую неустойчивость, второе может свидетельствовать об ограниченном доступе к внешнему финансированию. Кредитным организациям рекомендуется установить пороговые значения для инициирования углубленного мониторинга заемщиков;
- Оборачиваемость кредиторской задолженности. Показатель занимает вторую позицию по значимости и служит индикатором краткосрочной ликвидности. Снижение оборачиваемости кредиторской задолженности при одновременном росте дебиторской задолженности сигнализирует о формировании кассового разрыва. Рекомендуется разработка автоматизированных триггеров для выявления данного паттерна и включения заемщика в список компаний, требующих повышенного внимания;
- Ключевая ставка Центрального банка. Макроэкономический фактор демонстрирует значимое влияние на вероятность дефолта через механизм сжатия ликвидности в периоды монетарного ужесточения. В условиях роста процентных ставок целесообразна корректировка кредитной политики в сторону более консервативных параметров одобрения и усиленного мониторинга действующего портфеля.

3. Развитие системы раннего предупреждения

Модель CatBoost продемонстрировала способность обнаруживать признаки финансовых затруднений в среднем за 1.3 года до наступления дефолта с максимальным горизонтом прогнозирования до 3-4 лет. Данная

характеристика позволяет реализовать проактивный подход к управлению кредитным риском:

- Динамическая переоценка риска: для компаний, демонстрирующих ухудшение финансовых показателей, рекомендуется сокращение периодичности пересчета вероятности дефолта с годовой до ежеквартальной;
- Превентивные интервенции: раннее выявление проблемных заемщиков создает возможность для своевременной реструктуризации задолженности или реализации мер финансового оздоровления;
- Установление триггеров досрочного взыскания: комбинация факторов может служить основанием для инициирования процедур досрочного истребования задолженности.

Рекомендации для регуляторов финансового рынка

1. Интеграция в нормативную базу пруденциального надзора

Разработанная модель может служить методологической основой для расчета вероятности дефолта (PD) в рамках внутренних рейтинговых подходов (IRB) согласно требованиям Basel III. Однако необходима адаптация модели к регуляторным стандартам:

- Калибровка под Through-The-Cycle (TTC) подход: текущая модель ориентирована на оценку Point-in-Time вероятности дефолта, отражающую текущие экономические условия. Для регуляторных целей требуется корректировка на долгосрочный экономический цикл путем замены краткосрочных макроэкономических переменных на их циклически скорректированные аналоги;
- Валидация и бэкестинг: модель должна проходить регулярную валидацию на out-of-time и out-of-sample выборках.

2. Требования к концентрации рисков

Результаты демонстрируют существенную дифференциацию уровня риска по отраслевому и географическому признакам. Рекомендуется

разработка нормативов, ограничивающих концентрацию кредитного портфеля банка в высокорисковых отраслях и регионах с целью предотвращения системного риска.

Рекомендации для субъектов малого и среднего предпринимательства

1. Самодиагностика финансового состояния

Выявленные критические факторы риска могут служить основой для разработки внутренней системы финансового мониторинга в компаниях МСП. Рекомендуется регулярная (ежеквартальная) оценка следующих показателей:

- Соотношение совокупного долга к собственному капиталу;
- Рентабельность активов (ROA);
- Оборачиваемость кредиторской и дебиторской задолженности;
- Коэффициент текущей ликвидности;
- Рентабельность продаж

Значительное отклонение показателей от отраслевых нормативов или негативная динамика по нескольким индикаторам одновременно должны служить сигналом для разработки плана финансового оздоровления.

2. Проактивное взаимодействие с кредиторами

Компаниям, находящимся в зоне среднего риска, рекомендуется проактивная коммуникация с кредитными организациями. Добровольное предоставление управленческой отчетности и демонстрация траектории улучшения ключевых финансовых показателей может способствовать более благоприятным условиям кредитования.

Заключение

В рамках данного исследования была разработана, валидирована и сравнена комплексная система оценки вероятности дефолта (PD) для российских малых и средних предприятий (МСП) на основе методов статистического анализа и машинного обучения. Работа была направлена на решение актуальной задачи повышения точности и объективности кредитного скоринга в сегменте, характеризующемся высокой информационной асимметрией и чувствительностью к макроэкономическим шокам. Все гипотезы подтвердились:

Гипотеза Н1 о ключевой роли показателей самофинансирования, лeverиджа и операционной эффективности для прогнозирования дефолта МСП нашла свое подтверждение. Анализ важности признаков в обеих моделях, особенно в CatBoost, выявил, что такие факторы, как Оборачиваемость кредиторской задолженности, Соотношение совокупного долга к капиталу и Рентабельность активов (ROA), являются наиболее значимыми предикторами. При этом подтвердился тезис о специфике МСП: традиционные показатели ликвидности (текущей и быстрой) оказались менее информативны, уступая метрикам, отражающим долгосрочную устойчивость и качество управления оборотным капиталом.

Гипотеза Н2 о существенном влиянии макроэкономических факторов на PD МСП также была подтверждена. Показатель «Ключевая ставка ЦБ РФ» стабильно вошел в число топ-признаков в моделях, демонстрируя, что стоимость фондирования является системным драйвером кредитного риска для всего сегмента. Это подтверждает высокую чувствительность МСП к внешней экономической среде и необходимость ее учета в моделях оценки риска.

Гипотеза Н3 о превосходстве алгоритмов градиентного бустинга над классическими методами в контексте риск-взвешенной производительности получила убедительное эмпирическое подтверждение. Модель CatBoost продемонстрировала статистически значимое превосходство

над логистической регрессией по всем ключевым метрикам: AUC-ROC (0.941 против 0.924), Gini-коэффициенту и, что наиболее важно для практики, по показателю Recall на уровне компаний (96.4% против 81.4%). Это означает, что CatBoost эффективнее выявляет потенциальных дефолтеров, минимизируя риск пропуска неблагонадежных заемщиков. При этом модель сохранила приемлемый уровень интерпретируемости благодаря применению метода SHAP, что отвечает регуляторным требованиям к прозрачности решений.

Ключевые результаты и достоинства работы:

- Разработаны и сравнены две рабочие модели PD: классическая, но робастная модель логистической регрессии с L1-регуляризацией и продвинутая модель градиентного бустинга CatBoost. Обе модели показали высокое качество ($\text{AUC-ROC} > 0.92$), подтвердив свою применимость для оценки кредитных рисков МСП;
- Создана эффективная система раннего предупреждения (Early Warning System): Обе модели, особенно CatBoost, способны выявлять признаки финансового напряжения в среднем за 1.3–1.9 года до наступления дефолта, с максимальным горизонтом прогнозирования до 3–4 лет. Это открывает возможности для проактивного управления рисками и своевременного вмешательства;
- Обеспечена интерпретируемость сложной модели: Использование SHAP-анализа для CatBoost позволило «заглянуть в черный ящик» и выявить нелинейные и сложные зависимости (например, U-образную связь между уровнем долга и риском), что ценно как для аналитиков, так и для регуляторов;
- Методологическая строгость: Исследование опирается на репрезентативную выборку реальных данных из системы СПАРК, использует корректные методы валидации с учетом панельной структуры данных (GroupShuffleSplit), что минимизирует риск переобучения и обеспечивает надежность результатов;

— Практическая ориентированность: Результаты работы сформулированы в виде конкретных рекомендаций для ключевых стейкхолдеров: кредитных организаций (внедрение многоуровневого скоринга, приоритетный мониторинг), регуляторов (адаптация нормативной базы) и самих МСП (инструменты самодиагностики).

В качестве перспектив дальнейшего развития модели можно выделить:

- Интеграцию альтернативных источников данных (ежеквартальная отчетность, данные о транзакциях, новостной фон, данные из госреестров);
- Разработку подхода к оценке риска для start-up компаний с короткой историей;
- Углубление стресс-тестирования модели на различных макроэкономических сценариях.

Проведенное исследование успешно достигло поставленной цели. Подтверждены выдвинутые гипотезы, разработаны и всесторонне протестированы две эффективные модели прогнозирования дефолта МСП. Доказано, что современные методы машинного обучения (CatBoost), дополненные инструментами объяснимого ИИ (SHAP), позволяют существенно повысить точность и заблаговременность оценки кредитного риска по сравнению с классическими подходами, сохраняя при этом необходимый уровень прозрачности. Полученные результаты имеют значительную практическую ценность для повышения эффективности риск-менеджмента в банковском секторе и устойчивости кредитования одного из ключевых сегментов российской экономики.

Наша команда состояла из трех участников ,каждый из которых выполнял ряд задач:

Билык Екатерина: построение и оценка моделей, выбор методов анализа, проверка устойчивости моделей, визуализация результатов, формирование рекомендаций

Лучков Павел: поиск и сбор данных, формирование и очистка выборки, проверка качества данных, подготовка признаков, участие в анализе результатов

Триллер Анна: анализ литературы, подготовка литературного обзора, подбор факторов, интерпретация результатов, формирование выводов и ограничений

СПИСОК ИСТОЧНИКОВ

1. Adian, Ikmal, et al. "Small and medium enterprises in the pandemic." Policy research working paper, 9414, World Bank IFC (2020).
2. Alaka, H., Oyedele, L., Owolabi, H., Akinade, O., Bilal, M., & Ajayi, S. (2018). A Big Data analytics approach for construction firms failure prediction models. *IEEE Transactions on Engineering Management*.
3. Alonso Robisco, Andrés, and José Manuel Carbó Martínez. "Measuring the model risk-adjusted performance of machine learning algorithms in credit default prediction." *Financial Innovation* 8.1 (2022): 70.
4. Altman, Edward I. "Financial ratios, discriminant analysis and the prediction of corporate bankruptcy." *The journal of finance* 23.4 (1968): 589-609.
5. Altman, Edward I., and Gabriele Sabato. "Modelling credit risk for SMEs: Evidence from the US market." *Abacus* 43.3 (2007): 332-357.
6. Altman, E. I., & Sabato, G. (2007). Modelling credit risk for SMEs: Evidence from the U.S. market. *Abacus*, 43(3), 332–357.
7. Altman, E. I., Sabato, G., & Wilson, N. (2010). The value of non-financial information in SME risk management. *The Journal of Credit Risk*, 6(2), 1–33.
8. Berger, A. N., & Udell, S. (2007). Small business credit scoring and credit availability. *Journal of Small Business Management*, 45(1), 5–22. <https://doi.org/10.1111/j.1540-627X.2007.00195.x>
9. Carpenter, R. E., & Petersen, B. C. Is the growth of small firms constrained by internal finance? // *Review of Economics and statistics*. – 2002. – Vol. 84. – №. 2. – P. 298-309.
10. Ciampi, Francesco. "Corporate governance characteristics and default prediction modeling for small enterprises. An empirical analysis of Italian firms." *Journal of Business Research* 68.5 (2015): 1012-1025.
11. Ciampi, F. (2018). Using corporate social responsibility orientation characteristics for small enterprise default prediction. *WSEAS Transactions on Business and Economics*, 15, 113–127.
12. Ciampi, Francesco, et al. "Rethinking SME default prediction: a systematic literature review and future perspectives." *Scientometrics* 126.3 (2021): 2141-2188.
13. Filipe, S. F., Grammatikos, T., & Michala, D. (2016). Forecasting distress in European SME portfolios. *Journal of Banking and Finance*, 64, 112–135.
14. Fosso Wamba, S., Akter, S., Edwards, A., Chopin, G., & Gnanzou, D. (2015). How ‘big data’ can make big impact: Findings from a systematic review and a longitudinal case study. *International Journal of Production Economics*, 165, 234–246.

15. Frame, W. S., & Woosley, L. (2004). Credit scoring and the availability of small business credit in low-and moderate-income areas. *Financial Review*, 39(1), 35–54.
16. Gabbianelli, L. (2018). A territorial perspective of SME's default prediction models. *Studies in Economics and Finance*, 35(4), 542–563.
17. Lundberg, Scott M., and Su-In Lee. "A unified approach to interpreting model predictions." *Advances in neural information processing systems* 30 (2017).
18. Manzaneque-Lizano, Montserrat, Esteban Alfaro-Cortes, and Alba María Priego de la Cruz. "Stakeholders and long-term sustainability of SMEs. Who really matters in crisis contexts, and when." *Sustainability* 11.23 (2019): 6551.
19. Министерство экономического развития Российской Федерации. Доклад о состоянии малого и среднего предпринимательства в Российской Федерации и мерах по его развитию за 2019–2023 гг. [Электронный ресурс]. – URL: economy.gov.ru/material/file/f1c2180f1319ea2480ac174fa780a37b/doklad_o_sostoyanii_msp_v_rf_i_merakh_po_ego_razvitiyu_za_2019_2023_gg.pdf (дата обращения: 27.11.2025).
20. Nooteboom, B. Innovation and diffusion in small firms: theory and evidence // *Small business economics*. – 1994. – Vol. 6. – P. 327-347.
21. OECD SME indicators, benchmarking and monitoring [Электронный ресурс]. – URL: <https://www.oecd.org/en/topics/sme-indicators-benchmarking-and-monitoring.html> (дата обращения: 10.12.2025).
22. Реестр малого и среднего бизнеса [Электронный ресурс] // Сравни.ру. – URL: <https://www.sravni.ru/biznes-kredity/info/reestr-malogo-i-srednego-biznesa/> (дата обращения: 10.12.2025).
23. Thomas, Nisha Mary. "Modeling key enablers influencing FinTechs offering SME credit services: A multi-stakeholder perspective." *Electronic Markets* 33.1 (2023): 18.

Приложение 1. Описательные статистики признаков

Признак	Count	Mean	Std	Min	25%	50%	75%	Max	Skewness	Kurtosis
Возраст компании, лет	31996	17.760	7.310	4.000	12.000	17.000	22.000	36.000	0.460	-0.650
Выручка, RUB (млн)	31996	241.404	403.031	1.831	38.241	80.477	232.128	2253.810	3.000	9.580
log_Выручка	31996	18.350	1.410	14.420	17.460	18.200	19.260	21.540	0.000	0.010
Коэффициент быстрой ликвидности, %	31996	2.250	4.090	0.020	0.430	0.890	1.830	21.120	3.380	11.520
Коэффициент обеспеченности собственными оборотными средствами, %	31996	-0.550	2.620	-12.120	-0.180	0.160	0.570	0.960	-3.450	11.610
Коэффициент оборачиваемости совокупных активов, %	31996	2.430	2.540	0.020	0.660	1.610	3.230	11.300	1.800	3.110
Коэффициент покрытия процентов по EBIT, %	31996	74.280	120.020	-13.950	2.790	27.400	112.560	609.610	2.940	9.620
Коэффициент текущей ликвидности, %	31996	3.870	6.740	0.110	0.990	1.450	3.280	34.800	3.370	11.430
Оборачиваемость дебиторской задолженности, разы	31996	15.210	28.190	0.200	2.500	5.500	13.200	146.600	3.430	11.970
Оборачиваемость кредиторской задолженности, разы	31996	11.880	17.300	0.100	2.100	5.500	13.200	83.100	2.660	7.150
Рентабельность активов (ROA), %	31996	0.060	0.240	-0.620	0.000	0.030	0.140	0.780	0.070	2.640
Рентабельность капитала (ROE), %	31996	0.340	0.740	-1.530	0.020	0.170	0.510	2.880	1.120	3.400
Рентабельность продаж, %	31996	0.000	0.300	-1.250	0.000	0.040	0.110	0.480	-2.570	8.180
Соотношение совокупного долга к капиталу, %	31996	0.900	2.960	-3.480	0.000	0.100	0.660	14.880	3.340	12.420
ВРП_на_душу	31996	710143.500	523761.700	230047.100	387043.400	510201.600	793485.000	2463550.000	1.810	2.580
USD_RUB_средневзвешенный	31996	67.030	6.570	58.350	62.710	64.740	72.150	85.250	0.940	0.910
Индекс_предпринимательской_уверенности	31996	-6.170	5.150	-19.000	-6.800	-4.000	-3.000	-1.800	-1.810	1.940
Ключевая_ставка_средняя	31996	8.330	2.270	4.940	7.250	7.420	10.540	12.540	0.180	-1.060

